

Cas Vision Desk

Computer Vision in Finance

Master 2 Finance, Data et IA — brief étudiant

Dhiya Lecheheb

2026

1 Question

Tâche fermée. Vous recevez une image financière (capture de graphique ou page de document). Construisez un **Vision Desk** : fine-tunez un ViT, exposez-le via des outils MCP, et laissez un LLM répondre *uniquement* à partir de ces outils.

Le livrable doit rendre trois points explicites :

1. **Assertion vision** — classe, score, champs structurés que le modèle peut soutenir ;
2. **Justification outil** — quel appel MCP et quel champ JSON justifient chaque affirmation ;
3. **Refus** — ce que vous ne concluez pas lorsqu'un outil échoue ou renvoie null.

Parallèle Signal Desk. Là où Signal Desk jugeait un LSTM *après coûts de transaction*, Vision Desk juge un agent LLM *après grounding*.

2 Support

Élément	Choix de la v1
Entrée	20–40 images annotées : type de graphique <i>ou</i> type de page (choix du groupe, fixé en séance).
Modèle vision	Vision Transformer (ViT) préentraîné, fine-tuné. Pas de LSTM.
Sortie vision	Classe + score, puis JSON conforme à un schéma (3–6 champs).
Agent	LLM + serveur MCP local (tools en lecture seule).

3 Outils MCP imposés

Tool	Fait	Ne fait pas
<code>vision.classify</code>	Classe + score	Interpréter le marché
<code>vision.extract</code>	JSON champs	Inventer un montant absent
<code>market.lookup</code>	Cotation / méta ticker	Lire l'image
<code>knowledge.search</code>	Glossaire / note méthodo	Remplacer la vision

Stubs acceptés pour `market.*` et `knowledge.*` s'ils sont documentés et déterministes.

4 Protocole obligatoire

1. Split par **document** (ou émetteur), pas un mélange aléatoire de pages du même PDF.
2. Preprocess du backbone tel que prescrit (mean/std ImageNet ou doc du checkpoint).
3. Publier F1 (macro ou par classe) hors échantillon + matrice de confusion.
4. Publier le schéma JSON *avant* l'inférence test.
5. Toute affirmation dans la réponse LLM doit citer un tool call et un champ.
6. Forcer un scénario d'échec d'outil et montrer refus / relance (pas d'invention).
7. Interdit : réponse LLM sans tool pour un fait « lu » dans l'image.

5 Ce que vous devez montrer

- ViT vs baseline séance 1, avec split propre par document ;
- JSON valide sur le held-out (schéma invalide = échec pipeline) ;
- une trace MCP **grounded** (tools → JSON → réponse) ;
- un **refus** après échec d'outil ou champ null ;
- trois limites écrites (layout shift, OCR / capture, hallucination, ...).

6 Livrables

Livrable	Contenu
Notebook / code	Données, ViT, schéma JSON, serveur MCP minimal, deux scénarios.
Note, 4 pages	Protocole, métriques vision, trace grounded, refus, trois limites.
Oral, 8–10 min	Une image, une trace d'outils, une limite. Défendre le grounding.

7 Lecture du résultat

La note porte sur le protocole, le grounding et les limites. Un refus clair après échec d'outil est mieux évalué qu'une phrase LLM polie sans JSON.

8 Variante — Doc Lens

Même science. Livrable = mini-outil de club : dépôt d'image, appel MCP, page exportée (classe, JSON, tools, trois limites). Pas de chat sans trace.

9 Ressources vidéo (préparation)

- StatQuest, *CNNs — image classification* — [youtube.com/watch?v=HGwBXDKFk9I](https://www.youtube.com/watch?v=HGwBXDKFk9I) ;
- 3Blue1Brown, *Attention in transformers* — [youtube.com/watch?v=eMlx5fFNoYc](https://www.youtube.com/watch?v=eMlx5fFNoYc) ;
- Yannic Kilcher, *ViT paper explained* — [youtube.com/watch?v=TrdevFK_am4](https://www.youtube.com/watch?v=TrdevFK_am4) ;
- Vision Transformer in PyTorch — [youtube.com/watch?v=ovB0ddFtzzA](https://www.youtube.com/watch?v=ovB0ddFtzzA) ;
- MCP (Anthropic) — [youtube.com/watch?v=CQywdSdi5iA](https://www.youtube.com/watch?v=CQywdSdi5iA) ;
- MCP en Python pour débutants — [youtube.com/watch?v=LYfr7qusVSs](https://www.youtube.com/watch?v=LYfr7qusVSs).

10 Checklist

- ☐ Jeu d'images et classes fixés en séance
- ☐ ViT (pas LSTM) + split par document

- ☐ Baseline avant le ViT
- ☐ Schéma JSON écrit avant le test
- ☐ Quatre tools MCP (stubs OK si documentés)
- ☐ Trace grounded + refus après échec d'outil
- ☐ Notebook + note 4 pages + oral